

推荐系统大作业实验报告

课程名称：推荐系统

姓名：

谭湘怡 (2025E8007382030)

管昊琛 (2025E8007382024)

郝彦棋 (2025E8009382012)

王语琦 (202518009029009)

丁佳铄 (2025E8001282002)

郭子宁 (2025E8018582021)

张一鸣 (2025E8018582016)

提交日期：

2026 年 5 月 18 日

1 引言

1.1 研究背景

随着电子商务的迅猛发展，海量商品信息导致了严重的信息超载问题，用户难以在海量候选库中快速找到所需商品。推荐系统作为缓解这一问题的核心技术，能够根据用户的历史行为、兴趣偏好及商品特征，精准预测并推送其最可能感兴趣的物品。本研究基于 McAuley 实验室于 2023 年发布的大规模亚马逊评论数据集（Amazon Reviews 2023），该数据集特征丰富，包含大量用户评论、商品元数据及共同购买图谱。为了深入探究序列推荐任务，我们在 Industrial & Scientific、Musical Instruments 以及 CDs & Vinyl 三个具有不同用户交互特性的商品类别上，开展了 Top-K 商品推荐的实验与分析。

1.2 研究意义

准确的 Top-K 商品推荐不仅能够显著提升用户的购物体验与检索效率，还能为电商平台带来巨大的商业转化价值。本次大作业通过构建给定长度为 n 的用户-商品交互时间序列，利用前 $n - 1$ 个交互历史预测未来的商品点击与购买行为。这一范式要求模型具备强大的序列建模能力（如 SASRec）。通过在真实工业级 5-Core 数据集上进行训练与验证，不仅有助于我们验证现有推荐算法在稀疏数据下的有效性，也为探索大语言模型（LLM）与传统推荐系统相融合的前沿方向打下了坚实的实践基础。

2 问题定义

本节先对序列推荐任务进行形式化的数学定义，并统一后续章节所用的符号表达。

2.1 符号定义

在本实验中，我们将历史交互数据集定义为元组 $(\mathcal{U}, \mathcal{I}, \mathcal{S})$ 。其中， $\mathcal{U}$ 代表全体用户的集合， $\mathcal{I}$ 代表全体物品（商品）的集合。

对于数据集中的任意一个用户 $u \in \mathcal{U}$ ，其按照时间先后顺序产生的历史交互记录可以表示为一个序列 $S^u = (i_1^u, i_2^u, \dots, i_k^u, \dots, i_{|S^u|}^u) \in \mathcal{S}$ 。其中， $i_k^u \in \mathcal{I}$ 代表用户 u 在第 k 次交互时点击或购买的物品 ID， $|S^u|$ 表示该用户的总交互次数。为了方便表达历史子序列，我们定义 $S_{1:k}^u = (i_1^u, i_2^u, \dots, i_k^u)$ 为用户 u 从第 1 步到第 k 步的局部交互历史。

在特征映射阶段，给定模型隐层维度 d ，全体物品将被映射为一个全局嵌入矩阵 $E \in \mathbb{R}^{|\mathcal{I}| \times d}$ 。对于子序列 $S_{1:k}^u$ ，其对应的特征矩阵表示为 $E_{1:k}^u = (E_{i_1^u}, E_{i_2^u}, \dots, E_{i_k^u}) \in \mathbb{R}^{k \times d}$ 。

2.2 序列推荐任务目标

序列推荐的核心目标是：基于用户已有的历史交互序列，预测其在下一个时间步最可能交互的物品。

本实验任务旨在学习一个包含参数集合 Θ 的序列推荐模型。给定用户前 k 步的上下文序列 $S_{1:k}^u$ ，模型需要输出用户在第 $k+1$ 步交互物品为 i_{k+1}^u 的条件概率 $p(i_{k+1}^u | S_{1:k}^u; \Theta)$ 。

在整体训练过程中，模型的优化目标是最大化整个数据集中所有序列的真实下一步交互预测的对数似然 (Log-Likelihood)。其等价的概率最大化目标函数可表示为：

$$\max_{\Theta} \prod_{u \in \mathcal{U}} \prod_{k=1}^{|S^u|-1} p(i_{k+1}^u | S_{1:k}^u; \Theta)$$

通过使用梯度下降算法优化参数 Θ 使上式最大化，模型即可学会在全局候选物品集 $\mathcal{I}$ 中为特定用户精准推断出下一个目标物品。

3 模型结构

本实验采用经典的序列推荐模型 SASRec 作为基础框架，原论文构建了一个纯基于注意力机制的序列学习框架，但在本实验的代码复现与落地中，为了提升深层网络的训练稳定性与计算效率，我们参考了 A-LLMRec 模型中的 SASRec 结构，引入了 Pre-LayerNorm、一维卷积前馈网络等优化设计。模型整体由嵌入层、自注意力层、前馈网络以及损失函数四部分组成。

3.1 嵌入层

在将用户的动态行为输入模型之前，首先将过长的用户历史截断或左侧填充为长度为 L 的定长序列 s ，对于长度不足的序列，使用 ID 为 0 的占位符进行 Padding。随后，模型通过商品嵌入层将离散商品 ID 映射为稠密向量表示：

$$E = \text{Embedding}(s)$$

为了消除填充项的影响，代码中设置 `padding_idx=0`，使填充位置始终映射为零向量，从而避免对模型训练产生干扰。模型进一步引入可学习的位置嵌入来增强序列中的位置信息：

$$\hat{E} = E \times \sqrt{d} + P$$

其中 d 为隐层维度， P 表示位置编码矩阵。随后，模型通过 Dropout 层进行正则化处理，以降低过拟合风险。此外，模型构建了时间序列掩码 `timeline_mask`，用于识别 Padding 位置，并在后续计算中将对应特征强制置零，从而保证无效位置不会参与注意力计算。

3.2 自注意力层

SASRec 的核心部分为多层 Transformer 自注意力结构。模型通过多头自注意力层实现序列内部的依赖建模，其输入 Query、Key 和 Value 均来自同一行为序列特征。为了解决深层网络梯度消失的问题，我们并未采用原论文默认的 Post-LN 结构，而是使用了在工程上表现更稳定的 Pre-LN 架构。对于第 i 层注意力模块，模型首先对输入进行层归一化：

$$Q = \text{LayerNorm}(X)$$

随后执行多头自注意力计算：

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V$$

其中：

$$Q = K = V$$

为了保证预测过程只能利用历史信息，模型构建了下三角因果掩码(`attention_mask`)，禁止当前位置访问未来时刻的商品信息，从而满足序列推荐中的自回归约束。在注意力输出后，模型采用残差连接：

$$X' = Q + \text{MHA}(Q, K, V)$$

该结构能够缓解深层网络训练中的梯度消失问题，并提高模型稳定性。

3.3 前馈网络

在每个注意力层之后，模型进一步使用逐点前馈网络 (Point-Wise Feed Forward Network) 对特征进行非线性变换。本实验中 FFN 采用了两个一维卷积层来实现，其结构如下：

$$\text{FFN}(x) = W_2(\text{ReLU}(W_1x + b_1)) + b_2$$

其中，两层卷积之间包含 ReLU 激活函数以及 Dropout 正则化。由于卷积核大小设置为 1，因此该结构本质上等价于对序列中每个位置分别执行独立的全连接映射，可以在不改变时序结构的情况下增强特征表达能力。FFN 输出后同样采用残差连接：

$$H = X' + \text{FFN}(X')$$

最后，经过全部 Transformer Block 后，模型再通过一层归一化层后得到最终序列表征：

$$F = \text{LayerNorm}(H)$$

其中序列最后一个位置的特征向量将作为用户当前兴趣表示。

3.4 损失函数

在训练阶段，模型采用正负采样策略构建监督信号。对于每个真实下一商品（正样本），随机采样一个用户未交互商品作为负样本。基于此，模型通过二分类学习方式区分用户真实偏好的商品与随机负样本，并利用损失函数对两类样本进行联合优化。模型首先计算用户序列表征与正负样本商品向量之间的内积得分：

$$\hat{y}_{pos} = F \cdot E_{pos}$$

$$\hat{y}_{neg} = F \cdot E_{neg}$$

其中， F 表示序列最终特征， E_{pos} 与 E_{neg} 分别表示正负样本的嵌入向量。

训练过程中，模型采用二元交叉熵损失（`BCEWithLogitsLoss`）进行优化，其目标是提高正样本得分并降低负样本得分：

$$\mathcal{L} = \sum_i [\text{BCE}(\hat{y}_{pos}^{(i)}, 1) + \text{BCE}(\hat{y}_{neg}^{(i)}, 0)]$$

其中，二元交叉熵损失内部集成了 Sigmoid 激活函数，能够提高数值稳定性并缓解梯度消失问题。在预测阶段，模型取序列最后一个位置的特征向量，与候选商品嵌入矩阵进行点积计算，并根据得分大小生成最终的 Top-K 推荐结果。

4 实验设置

4.1 数据集

4.1.1 数据集描述与预处理

本实验采用了由 McAuley 实验室发布的 **Amazon Reviews 2023** 大规模商品评论数据集。该数据集包含了海量的用户评论反馈与商品元数据，是当前推荐系统领域极具权威性的基准评测数据集之一。

为了全面评估模型在不同规模和领域下的推荐性能，本实验严格按照大作业要求，选取了以下三个不同商品类别的子数据集进行独立训练与测试：

- **Industrial & Scientific**（工业与科学用品）
- **Musical Instruments**（乐器）
- **CDs & Vinyl**（CD 与黑胶唱片）

在数据预处理阶段，为了避免极度稀疏的隐式反馈导致模型无法有效学习协同序列特征，本实验统一采用了原数据集的 **5-Core** 版本。该版本经过了严格的频次过滤，确保数据集中保留的每一个用户（`user_id`）和每一个商品（`parent_asin`）都至少拥有 5 条以上的交互记录。此外，针对提取出的交互序列，我们在代码中统一通过用户评论的

时间戳 (timestamp) 对行为进行绝对升序排序，以构建具有严格时间先后依赖关系的真实用户动态行为序列。

4.1.2 数据划分策略

在序列推荐任务中，常规的随机比例切分会严重破坏用户行为的时间因果性，引发用未来数据预测过去行为的数据穿越错误。因此，本实验严格采用了序列推荐领域标准的 **留一法 (Leave-One-Out)** 时序划分策略。

具体而言，对于任意一个在时间维度上排序完毕、总长度为 N 的用户交互序列 $S^u = (i_1, i_2, \dots, i_N)$ ，我们进行如下确定性切分：

- **训练集**：取序列的前 $N-2$ 个交互记录 $(i_1, \dots, i_{N-2})$ ，用于 SASRec 模型内部 BCE 损失的常规反向传播与参数更新。
- **验证集**：取序列的第 $N-1$ 个交互记录 (i_{N-1}) 。在评估时，模型以上文训练集序列为历史输入，预测该商品，以监测模型的收敛状态并用于超参数调优。
- **测试集**：取序列的最末尾、即第 N 个交互记录 (i_N) 。评估时，模型以“训练集 $\cup$ 验证物品”作为历史前缀输入，预测该最终商品，作为衡量模型泛化能力的最终标准。

4.2 评估方式与指标

在模型的性能验证与测试阶段，为了避免对全局数万个候选商品进行穷举打分带来的极高计算开销，本实验采用了 **1-vs-100** 的目标排序评估协议。

对于每一个用户的测试（或验证）目标，模型构建了一个大小为 101 的候选池：包含 1 个真实的 Ground-Truth 物品，以及 100 个由 WarpSampler 随机采样、且该用户从未交互过的负样本物品。模型针对这 101 个候选物品输出预测概率并进行降序排列。此外，若测试集的用户规模大于 10,000，评估脚本会随机子采样 10,000 名用户进行指标计算，以加速评估过程。

最终，我们要求模型为每条测试数据预测 Top-10 推荐列表，并采用以下两项主流指标衡量排序质量：

- **HR@10 (Hit Ratio)**：命中率。只要真实目标物品出现在模型预测的前 10 名列表内（即排序 $\text{rank} < 10$ ），即视为命中（记为 1，否则为 0）。该指标直观反映了模型是否推中商品的能力。
- **NDCG@10 (Normalized Discounted Cumulative Gain)**：归一化折损累计收益。该指标不仅要求推中，还严格考察商品排名的靠前程度。对于命中的真实物品，其贡献的增益按照 $1/\log_2(\text{rank} + 2)$ 衰减，排名越靠后得分越低，未命中则得分为 0。

4.3 模型训练细节与超参数设置

4.3.1 训练设置与优化器

本实验采用了 Adam 优化器。初始学习率设定为 $lr = 0.001$ ，这与 Adam 在本任务中的常用收敛策略保持一致，能有效确保训练过程的平稳性，使验证集指标随 Epoch 呈良性上升趋势。模型的总体训练轮数设定为 50 轮，并且规定每隔 5 个 Epoch 在验证集和测试集上进行一次完整的指标评估，以此在训练效率与模型收敛状态的实时监测之间取得最佳折中。为了充分利用显卡显存并加速深度自注意力网络的并行矩阵计算，实验将模型的训练 `batch_size` 设定为 256。

4.3.2 核心超参数配置

本实验的核心结构与正则化超参数综合参考了 SASRec 原论文的推荐设置与本组的调优反馈。

- **序列截断长度 (`maxlen = 50`)**: 主要考虑到 Amazon 评论子集的用户平均行为序列长度有限，50 这一阈值足以覆盖绝大多数用户的核心时序上下文，从而在捕捉长短期兴趣与降低显存开销之间实现了良好的平衡。
- **网络失活率 (`dropout_rate = 0.5`)**: 由于 Amazon 隐式反馈数据集具有高维稀疏特征，深层神经网络极易在训练集上陷入过拟合。为此，本组采用了较强的 0.5 作为 Dropout 概率，通过在训练过程中随机失活注意力权重与前馈层神经元，有效缓解了过拟合现象，显著提升了模型在测试集上的泛化表现。

为了在三个不同的商品品类之间进行公平的横向对比，本实验让三个类别共用了同一套最优参数配置，具体汇总如表 1 所示：

表 1: SASRec 模型核心超参数设置

超参数	数值	简要说明
<code>lr</code>	0.001	Adam 学习率
<code>maxlen</code>	50	用户行为序列截断长度
<code>dropout_rate</code>	0.5	注意力与前馈层中的 Dropout
<code>batch_size</code>	256	批大小
<code>num_epochs</code>	50	训练总轮数
<code>eval_every</code>	5	每 5 个 epoch 在验证集与测试集上评估一次（第 1 个 epoch 亦会评估）
<code>eval_seed</code>	42	评估时随机负采样等操作的随机种子，保证结果可复现
<code>hidden_units</code>	50	隐层维度
<code>num_blocks</code>	2	Transformer 块数
<code>num_heads</code>	1	注意力头数
<code>l2_emb</code>	0.0	物品嵌入 L2 正则系数
<code>n_workers</code>	1	数据采样进程数 (Windows 环境下建议为 1)

5 实验结果

本节将全面展示 SASRec 模型在三个 Amazon 商品子集上的推荐性能。评估过程严格基于测试集数据，并从整体推荐性能、模型收敛过程、以及注意力机制的可视化三个维度进行深入剖析。

5.1 整体推荐性能评估

在模型训练至第 50 个 Epoch 结束后，我们在测试集上进行了全量排序评估。模型针对每条测试数据预测了 Top-10 商品列表，最终在三个数据集上的 HR@10 和 NDCG@10 如表 2 所示。

表 2: SASRec 模型在各测试集上的最终性能

数据集类别	测试集 HR@10	测试集 NDCG@10
CDs & Vinyl	0.3249	0.3121
Industrial & Scientific	0.3225	0.3110
Musical Instruments	0.3374	0.3173

5.2 Top-10 推荐结果分析

为了进一步验证模型的实际推荐能力，实验使用训练完成后的最优模型，对 User ID: 10 进行了 Top-10 推荐测试。模型以用户最近 50 次交互行为作为输入，在全物品集合中生成排序最高的 10 个候选物品。

三个数据集上的预测结果如表3：

表 3: SASRec 模型预测 Top-10 推荐物品 ID 列表

数据集类别	Top-10 推荐物品 ID 列表
CDs & Vinyl	[27008, 654, 677, 266, 272, 5744, 33696, 17456, 28419, 2370]
Industrial & Scientific	[17085, 2687, 2669, 3400, 1035, 2800, 14501, 1210, 1242, 837]
Musical Instruments	[493, 216, 2378, 10462, 2675, 1329, 3795, 2945, 40, 202]

从结果可以看出，模型能够基于用户历史行为生成稳定的候选推荐序列，说明 SASRec 模型已能够有效学习用户兴趣的时序变化规律。同时，不同数据集生成的推荐结果具有明显差异，也反映出模型能够根据不同领域的行为模式学习对应的用户偏好特征。

5.3 模型训练与收敛动态分析

为了探究自注意力架构的训练稳定性，我们记录并可视化了模型在 50 个 Epoch 内的测试集 NDCG@10 变化曲线。

结合曲线图可以发现，三类数据集的收敛情况呈现出高度一致的规律：




图 1: CDs & Vinyl 类别的测试集 NDCG@10 变化曲线




图 2: Industrial & Scientific 类别的测试集 NDCG@10 变化曲线




图 3: Musical Instruments 类别的测试集 NDCG@10 变化曲线

- **Epoch 1-15:** 模型处于欠拟合状态，NDCG@10 指标呈直线拉升。
- **Epoch 20-50:** 指标在达到局部最优后开始震荡走平。在 50 个 epoch 的迭代后，模型在三个数据集上均未出现验证集/测试集指标显著掉头的过拟合崩塌现象。

5.4 注意力机制可视化研究

为了进一步探究 SASRec 模型在进行序列推理时的内部决策机理，我们获取了模型在推断阶段最后一层 Transformer 的注意力权重矩阵。

本实验以三个数据集中的 **User 10** 为追踪对象，提取了其在预测目标物品时，模型对历史序列中各物品分配的注意力权重，并将其渲染为一维热力图进行横向对比分析，如图 4、5和6所示。




图 4: CDs & Vinyl 类别的自注意力机制权重分配热力图

根据热力图我们可以分析得到：

- **近期行为主导偏好:** 从图 5 的 **Industrial & Scientific** 热力图可以看出，注意力权重整体呈递增趋势。模型对序列前部物品（如 ID 171、172）的关注度较低，而




图 5: Industrial & Scientific 类别的自注意力机制权重分配热力图




图 6: Musical Instruments 类别的自注意力机制权重分配热力图

对序列后部的近期物品（如 ID 14916、24809）赋予了更高权重。这说明 SASRec 在预测下一物品时，更倾向于关注用户最近的交互行为，验证了短期兴趣对推荐结果的重要影响。

- **自适应上下文感知能力：**进一步对比图 4和6可以发现，模型并不会始终将最高注意力分配给序列最后一个物品。在 **Musical Instruments** 数据集中，权重最高的是倒数第二个物品（ID 989）；在 **CDs & Vinyl** 数据集中，倒数第二和第三个物品（ID 281、13904）同样获得了更高权重，而最后一个物品的权重相对较低。

这一现象表明，SASRec 并非简单依赖最近一次行为，而是能够结合整个序列的上下文信息，自适应地选择对当前预测最有帮助的历史物品。当序列末尾存在噪声行为或弱相关交互时，模型能够降低其影响，转而关注更具有协同关系的历史行为。这也是自注意力机制相比传统一阶马尔可夫链模型的重要优势。

6 可重复性说明

6.1 运行环境

本项目的所有实验均在以下环境中运行与验证：

- **操作系统：** Windows 11（代码跨平台，Linux/macOS 同样适用）。
- **Python 版本：** 3.10。

- **环境管理**：Conda（环境名 llmrec）。
- **深度学习框架**：PyTorch $\geq 2.1.0$ （按本机 CUDA 版本从 pytorch.org 安装）。
- **硬件加速**：支持 NVIDIA GPU（CUDA）与 CPU 两种模式，GPU 非必需。

6.2 依赖库

项目依赖以下 Python 第三方库，版本与用途如表 4 所示：

表 4: 项目依赖库及版本要求

库名	版本	用途
torch	$\geq 2.1.0$	深度学习框架，模型定义、训练与推理
numpy	$\geq 1.26.0$	数值计算，矩阵运算与随机数生成
tqdm	$\geq 4.64.0$	训练与数据预处理进度条显示
pytz	≥ 2023.3	时区处理（日志时间戳本地化）
pandas	$\geq 2.0.0$	结构化数据读取与预处理 (CSV/TSV/JSON.gz)
requests	$\geq 2.31.0$	HTTP 客户端，从 UCSD 下载 Amazon 2023 数据集
transformers	$== 4.32.1$	Hugging Face Transformers, LLM 模型加载与推理
huggingface_hub	$\geq 0.14.0, < 0.26.0$	Hugging Face 模型仓库访问与缓存
sentence-transformers	$== 2.2.2$	文本嵌入模型，用于语义表示与相似度计算
accelerate	$\geq 0.25.0$	分布式训练加速与混合精度（FP16/BF16）
bitsandbytes	$\geq 0.42.0$	模型量化推理（INT8/INT4），降低显存占用
matplotlib	$\geq 3.7.0$	数据可视化：训练曲线、NDCG 收敛图等
seaborn	$\geq 0.12.0$	统计可视化：注意力权重热力图

环境安装命令如下：

```
conda create -n llmrec python=3.10
conda activate llmrec
pip install -r requirements.txt
```

6.3 运行步骤

完整复现本实验需依次执行以下 7 个步骤。三个数据集类别分别为 Industrial_and_Scientific、Musical_Instruments、CDs_and_Vinyl，下文中以 < 类别 > 代指。

步骤 1：下载原始数据

```
python scripts/download_amazon5core.py
```

该脚本从 UCSD McAuley Lab 下载 Amazon 2023 5-Core 基准数据集，自动获取各分类的训练集、验证集与测试集。

步骤 2：检查原始数据完整性

```
python scripts/check_raw_data.py
```

步骤 3：数据预处理

```
python scripts/preprocess_to_seqrec.py --categories < 类别 > --overwrite
```

该步骤完成以下工作：筛选有效用户（交互数 ≥ 3 ）、构建用户/物品 ID 映射、按时间顺序划分序列、生成 SASRec 格式的训练/验证/测试文件。

步骤 4：检查预处理结果

```
python scripts/check_processed_data.py --categories Industrial_and_Scientific  
Musical_Instruments CDs_and_Vinyl
```

步骤 5：训练模型

```
python pre_train/sasrec/main.py --dataset < 类别 > --skip_preprocess  
--device cuda:0 --eval_seed 42
```

该步骤启动 SASRec 模型训练。`--skip_preprocess` 跳过原始 JSON.gz 解析，直接读取已预处理数据。`--eval_seed 42` 固定评估阶段的随机种子，`--device` 可改为 `cpu` 在无 GPU 环境下运行。

步骤 6：独立评估

```
python pre_train/sasrec/main.py --dataset < 类别 > --device cuda:0  
--inference_only --state_dict_path pre_train/sasrec/< 类别 >/SASRec.epoch=<N>.ptl
```

加载训练好的最优模型权重，在测试集上计算 NDCG@10 和 HitRate@10 两项核心指标。此模式复用训练脚本内置的评估函数，与训练过程中的定期评估使用相同的随机种子与负采样逻辑，保证结果可比。

步骤 7：运行完整性测试

```
python scripts/test_project.py
```

该脚本执行端到端测试，验证数据加载、模型前向传播、评估指标和配置文件解析等功能模块均正常运行。

6.4 随机种子

为确保实验结果可复现，本项目的所有实验均固定随机种子为 42。具体而言：

- SASRec 训练脚本 (`pre_train/sasrec/main.py`) 通过 `--eval_seed 42` (默认值) 在每次评估前固定 Python 内部的 `random` 与 NumPy 随机数生成器，确保验证和测试时的用户子采样 (大于 10000 用户时随机抽取 10000 名) 与负样本集合完全可复现。
- 独立评估脚本 `evaluation/NDCG@10_eval.py` 在模块级固定 `random.seed(42)`、`np.random.seed(42)` 与 `torch.manual_seed(42)`，保证脱离训练流程后的独立推理结果可复现。
- 数据预处理阶段按文件顺序读取用户，不使用随机抽样，因此处理结果在相同输入下完全确定。

7 团队分工

本项目的研发与报告撰写由团队全体成员协同完成。团队内部实行模块化分工，涵盖数据预处理、模型构建、调优实验、效果评估及文档撰写等全流程。具体的团队成员分工与核心职责如表 5 所示。

表 5: 团队成员分工与具体职责表

姓名	负责部分	具体职责
郝彦棋	数据预处理	1. 下载大作业说明中的 Amazon Reviews 2023 三个 5-Core 数据集。 2. 按大作业说明中的要求划分: 训练集 = 前 N-2、验证集 = 第 N-1、测试集 = 第 N。 3. 将数据转换为 SASRec 所需格式。
丁佳烁	确认数据能正常加载	1. 修改数据加载部分, 读取三个类别数据。 2. 调整序列长度 maxlen、padding 等参数。 3. 确保训练/验证/测试划分与作业一致。
谭湘怡	模型配置与训练脚本	1. 调整超参数配置 (嵌入维度、注意力头数、dropout 率等)。 2. 修改训练脚本支持多数据集切换、早停、模型保存。 3. 添加 NDCG@10 评估函数, 确认评估方式符合作业要求。
管昊琛	训练与调优	1. 在三个类别上运行训练脚本, 调节关键超参数 (maxlen、dropout_rate、学习率等)。 2. 使用验证集监控 NDCG@10, 记录实验配置和结果。 3. 确定每个类别最优超参数, 固定随机种子。 4. 输出最终模型检查点。
张一鸣	评估与结果分析	1. 用最优模型跑测试集, 输出 Top-10 预测。 2. 计算三个类别的 NDCG@10 等评估结果。 3. 生成图表: 训练损失曲线、NDCG 收敛曲线、注意力可视化等。 4. 确保结果可复现 (记录所有参数和种子)。
王语琦	报告撰写 A	1. 撰写问题定义、数据集描述、数据划分方法。 2. 详细描述 SASRec 模型结构 (嵌入、自注意力、掩码、FFN 等, 引用论文)。 3. 实验设置 (超参数表格、训练细节、硬件环境)。 4. 实验结果分析 (三个类别 NDCG@10 表格)。 5. 参考文献引用。
郭子宁	报告撰写 B	1. 撰写引言 (背景、研究意义)。 2. 撰写团队分工说明 (表格形式列出每人职责)。 3. 撰写可重复性说明 (运行环境、依赖、步骤、随机种子)。 4. 使用 Python 或 Excel 制作图表 (从评估人员处取数据图表)。 5. 检查报告格式统一、引用规范、错别字。

参考文献

- [1] Kang, Wang-Cheng and McAuley, Julian. Self-attentive sequential recommendation, *2018 IEEE international conference on data mining (ICDM)*, 197–206, 2018.
- [2] Kim, Sein and Kang, Hongseok and Choi, Seungyoon and Kim, Donghyun and Yang, Minchul and Park, Chanyoung. Large language models meet collaborative filtering: An efficient all-round llm-based recommender system, *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 1395–1406, 2024.